

Οι αναλυτικές σειρές ασκήσεων είναι ατομικές, και οι λύσεις που θα δώσετε πρέπει να αντιπροσωπεύουν μόνο την προσωπική σας εργασία. Εξηγήστε επαρκώς την εργασία σας. Αν χρησιμοποιήσετε κάποια άλλη πηγή εκτός των σημειώσεων για τη λύση σας, πρέπει να το αναφέρετε. Η παράδοση των λύσεων των αναλυτικών ασκήσεων της σειράς αυτής θα γίνει ηλεκτρονικά στο helios και θα πρέπει να την υποβάλετε ως ένα ενιαίο αρχείο PDF με το εξής filename format, χρησιμοποιώντας μόνο λατινικούς χαρακτήρες: pr25_hwk2_AM_FirstnameLastname.pdf, όπου AM είναι ο 8-ψήφιος αριθμός μητρώου σας. Σκαναρισμένες χειρόγραφες λύσεις επιτρέπονται, αρκεί να είναι καθαρογραμμένες και ευανάγνωστες. Επίσης, στην πρώτη σελίδα των λύσεων θα αναγράφετε το ονοματεπώνυμο, AM, και email address σας. Απαγορεύεται αυστηρά η ανάρτηση των λύσεων σε οποιαδήποτε πλατφόρμα καθώς το περιεχόμενο της άσκησης αποτελεί πνευματική ιδιοκτησία των διδασκόντων και της ομάδας υποστήριξης του μαθήματος. Οι αναλυτικές σειρές ασκήσεων είναι ατομικές, και οι λύσεις που θα δώσετε πρέπει να αντιπροσωπεύουν μόνο την προσωπική σας εργασία.

Υλικό για Ανάγνωση: Βιβλία: [1], [2], [3], [4], [5]
Διαφάνειες διαλέξεων μαθήματος

Αναλυτικές Ασκήσεις

Άσκηση 2.1: (Linear Discriminant Analysis)

Στο μάθημα είδαμε ότι η Linear Discriminant Analysis (LDA) βασίζεται στην ανάστροφη σχέση των μητρών (πινάκων) S_W και S_B :

$$S_W = \sum_{i=1}^{|Classes|} \mathbb{E}_{x|x \in \omega_i} [(\vec{x} - \vec{\mu})(\vec{x} - \vec{\mu})^T]$$
$$S_B = \sum_{i=1}^{|Classes|} P(\omega_i)(\vec{\mu}_i - \vec{\mu})(\vec{\mu}_i - \vec{\mu})^T$$

όπου το ω_i αναπαριστά μια κλάση με μέση τιμή $\vec{\mu}_i$, $|Classes|$ είναι το πλήθος των κλάσεων και $\vec{\mu}$ είναι η μέση τιμή όλων των δειγμάτων.

(α) Δείξτε ότι στην περίπτωση διαχωρισμού δύο κλάσεων ω_1 και ω_2 , ο πίνακας S_B μπορεί να γραφτεί στη μορφή $S_B = P(\omega_1)P(\omega_2)(\vec{\mu}_2 - \vec{\mu}_1)(\vec{\mu}_2 - \vec{\mu}_1)^T$.

(β) Βασιζόμενοι στο υποερώτημα (α), να βρείτε το ιδιοδιάνυσμα του πίνακα $S_W^{-1}S_B$ και την ιδιοτιμή του.

Άσκηση 2.2: (Logistic Regression)

Θεωρήστε το πρόβλημα logistic regression για ένα σύνολο δεδομένων $\{\phi_n, t_n\}$, όπου $t_n \in \{0, 1\}$ και $\phi_n = \phi(\mathbf{x}_n)$ είναι οι κατηγορίες και οι συναρτήσεις βάσης, αντίστοιχα, για δείγματα $n = \{1, 2, \dots, N\}$. Η συνάρτηση σφάλματος $E(\mathbf{w})$, η οποία αναφέρεται συνήθως και ως cross-entropy, ορίζεται ως:

$$E(\mathbf{w}) = - \sum_{n=1}^N \{t_n \ln y_n + (1 - t_n) \ln(1 - y_n)\}$$

όπου $\mathbf{w}$ είναι το διάνυσμα βαρών, $y_n = \sigma(\mathbf{w}^\top \phi_n)$ η έξοδος του μοντέλου logistic regression στο διάνυσμα εισόδου $\mathbf{x}_n$, και $\sigma(a) = \frac{1}{1+\exp(-a)}$ η logistic sigmoid συνάρτηση.

(α) Να δείξετε ότι για ένα γραμμικώς διαχωρίσιμο σύνολο δεδομένων, η λύση μέγιστης πιθανοφάνειας για το μοντέλο logistic regression αντιστοιχεί στην εύρεση ενός διανύσματος $\mathbf{w}$, για το οποίο η επιφάνεια απόφασης $\mathbf{w}^\top \phi(\mathbf{x}) = 0$ διαχωρίζει τις κλάσεις, απειρίζοντας ταυτόχρονα το μέτρο του διανύσματος $\mathbf{w}$.

(β) Η Hessian μήτρα για το logistic regression δίνεται από τη σχέση:

$$\mathbf{H} = [\Phi^\top \mathbf{R} \Phi]$$

όπου Φ είναι ο πίνακας των χαρακτηριστικών και $\mathbf{R}$ είναι ένας διαγώνιος πίνακας με στοιχεία $y_n(1 - y_n)$.

Να δείξετε ότι η Hessian μήτρα $\mathbf{H}$ είναι θετικά ορισμένη. Ως εκ τούτου, δείξτε ότι η συνάρτηση σφάλματος είναι κυρτή συνάρτηση του $\mathbf{w}$ και ότι έχει μοναδικό ελάχιστο.

(γ) Να γράψετε κώδικα που θα υλοποιεί τον iterative reweighted least squares (IWLS) αλγόριθμο για logistic regression. Χρησιμοποιώντας τον αλγόριθμο αυτό, να υπολογίσετε και να σχεδιάσετε τα διαχωριστικά επίπεδα απόφασης που αντιστοιχούν στο σύνολο δεδομένων του προβλήματος τριών κλάσεων που έχει ανεβεί στο mycourses (αρχείο MLR.data). Οι δύο πρώτες στήλες περιλαμβάνουν τα διανύσματα χαρακτηριστικών, ενώ η τρίτη την κλάση. Συγκρίνετε τα αποτελέσματα με εκείνα που θα προέκυπταν εάν εφαρμοζόταν ταξινόμηση με βάση τα ελάχιστα τετράγωνα, σχεδιάζοντας τα αντίστοιχα διαχωριστικά επίπεδα απόφασης.

Σημείωση: Λεπτομέρειες από θεωρία του logistic regression και IWLS μπορούν να βρεθούν στις σχετικές διαφάνειες του μαθήματος και τις ενότητες 4.3.2, 4.3.3, 4.3.4 από [3].

Άσκηση 2.3: (Cross-entropy)

Για την ακόλουθη cross-entropy συνάρτηση κόστους

$$J = - \sum_{i=1}^N \sum_{k=1}^{k_L} y_k(i) \ln \left(\frac{\hat{y}_k(i)}{y_k(i)} \right)$$

όπου k_L είναι ο αριθμός των κόμβων εξόδου, N ο αριθμός των δειγμάτων, $y_k(i)$ οι επιθυμητές πιθανότητες στην έξοδο του multilayer perceptron, και $\hat{y}_k(i)$ οι πραγματικές πιθανότητες στην έξοδο:

(α) Δείξτε ότι η ελάχιστη τιμή της για δυαδικές επιθυμητές τιμές εξόδου (δηλ. τιμές 0,1) είναι μηδενική και προκύπτει όταν οι πραγματικές έξοδοι είναι ίσες με τις επιθυμητές.

(β) Δείξτε ότι η cross-entropy συνάρτηση κόστους εξαρτάται από τα σχετικά σφάλματα εξόδου.

Άσκηση 2.4: (Bayesian parameter estimation)

Έστω ότι η κατανομή $p(\mathbf{x}|\mathbf{\Sigma})$ ακολουθεί την κανονική κατανομή $\mathcal{N}(\boldsymbol{\mu}, \mathbf{\Sigma})$, όπου το διάνυσμα μέσης τιμής $\boldsymbol{\mu}$ θεωρείται γνωστό και ο πίνακας συνδιασποράς $\mathbf{\Sigma}$ άγνωστος. Εάν έχουμε n δεδομένα $x_1, \dots, x_n$, να δείξετε ότι ο εκτιμητής μέγιστης πιθανοφάνειας του $\mathbf{\Sigma}$ δίνεται από τη σχέση:

$$\hat{\mathbf{\Sigma}} = \frac{1}{n} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^T$$

Για να το αποδείξετε ακολουθήστε τα παρακάτω βήματα:

(α) Αποδείξτε την ιδιότητα $\mathbf{a}^T \mathbf{A} \mathbf{a} = \text{trace}(\mathbf{A} \mathbf{a} \mathbf{a}^T)$, όπου το ίχνος (trace) είναι το άθροισμα των διαγώνιων στοιχείων του πίνακα $\mathbf{A}$.

(β) Δείξτε ότι η συνάρτηση πιθανοφάνειας μπορεί να γραφεί στη μορφή:

$$p(\mathbf{x}_1, \dots, \mathbf{x}_n | \mathbf{\Sigma}) = \frac{1}{(2\pi)^{nd/2} |\hat{\mathbf{\Sigma}}|^{n/2}} \exp \left(-\frac{1}{2} \text{trace}(\mathbf{\Sigma}^{-1} \sum_{k=1}^n (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^T) \right)$$

(γ) Έστω ότι $\mathbf{A} = \mathbf{\Sigma}^{-1} \hat{\mathbf{\Sigma}}$ και $\lambda_1, \dots, \lambda_n$ οι ιδιοτιμές του $\mathbf{A}$. Δείξτε ότι το παραπάνω αποτέλεσμα οδηγεί στη σχέση

$$p(\mathbf{x}_1, \dots, \mathbf{x}_n | \mathbf{\Sigma}) = \frac{1}{(2\pi)^{nd/2} |\hat{\mathbf{\Sigma}}|^{n/2}} (\lambda_1 \cdots \lambda_d)^{n/2} \exp \left(-\frac{n}{2} \sum_{i=1}^d \lambda_i \right)$$

(δ) Ολοκληρώστε την απόδειξη δείχνοντας ότι η πιθανοφάνεια μεγιστοποιείται με την επιλογή $\lambda_1 = \cdots \lambda_d = 1$. Εξηγήστε αναλυτικά.

Άσκηση 2.5: (Karhunen–Loeve Transform–KLT, PCA)

Σύνοψη Θεωρίας: Υποθέτουμε τυχαία διανύσματα $\mathbf{x} \in \mathbb{C}^d$ (που μπορεί να παριστάνουν χαρακτηριστικά σε πρόβλημα αναγνώρισης προτύπων, γενικά με μιγαδικές τιμές). Ο αντίστοιχος χώρος Hilbert έχει εσωτερικό γινόμενο

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathcal{E}\{\mathbf{y}^H \mathbf{x}\}.$$

Η ενέργεια του κάθε τυχαίου διανύσματος ισούται με

$$\langle \mathbf{x}, \mathbf{x} \rangle = \mathcal{E}\{\mathbf{x}^H \mathbf{x}\} = \mathcal{E}\{\|\mathbf{x}\|^2\}.$$

Θέλουμε να βρούμε ένα unitary γραμμικό μετασχηματισμό (πίνακα) $\mathbf{A}$ ώστε τα μετασχηματισμένα διανύσματα

$$\mathbf{y} = \mathbf{A}^H \mathbf{x}, \quad \mathbf{A}^{-1} = \mathbf{A}^H,$$

να έχουν δύο ιδιότητες: (1) να έχουν ορθογώνιες συνιστώσες, και (2) αν κρατήσουμε μόνο τις πρώτες $p < d$ συνιστώσες να έχουμε ελάχιστο μέσο τετραγωνικό λάθος (Mean Squared Error–MSE). Η λύση και βέλτιστη επιλογή είναι ο Karhunen–Loeve μετασχηματισμός KLT, γνωστός και ως Principal Component Analysis (PCA). Συγκεκριμένα, επιλέγουμε τις στήλες του $\mathbf{A}$ τα ορθοκανονικά διανύσματα $\{\mathbf{e}_1, \dots, \mathbf{e}_d\}$ που είναι τα ιδιοδιανύσματα του

$$\mathbf{R}_x = \mathcal{E}\{\mathbf{x} \mathbf{x}^H\}.$$

Από αυτά, τα πρώτα p ιδιοδιανύσματα $\{\mathbf{e}_1, \dots, \mathbf{e}_p\}$ αντιστοιχούν στις p μεγαλύτερες ιδιοτιμές $\lambda_1 \geq \dots \geq \lambda_p$. Η τάξης- p βέλτιστη προσέγγιση $\hat{\mathbf{x}}$ και το αντίστοιχο ελάχιστο MSE J είναι:

$$\hat{\mathbf{x}} = \sum_{k=1}^p y_k \mathbf{e}_k, \quad y_k = \mathbf{e}_k^H \mathbf{x},$$

$$J = \mathcal{E}\{\|\mathbf{x} - \hat{\mathbf{x}}\|^2\}.$$

Με τις ανωτέρω επιλογές, τα μετασχηματισμένα χαρακτηριστικά $\{y_i\}$ είναι ορθογώνια.

ΠΡΟΣ ΑΠΟΔΕΙΞΗ: (Inductive or Batch matrix solution of PCA)

- (a) Assuming that we have solved the PCA problem for the case $p = 1$, prove the general case where p is any integer $1 < p < d$ by using the principle of induction.
- (b) Show that the minimum value of the PCA error J with respect to the $\mathbf{e}_i$, subject to the orthonormality constraints, is obtained when the $\mathbf{e}_i$ are eigenvectors of the correlation (or covariance) matrix. To do this, introduce a matrix $\mathbf{H}$ of Lagrange multipliers, one for each constraint, so that the modified distortion measure, in matrix notation reads

$$\tilde{J} = \text{Trace}\{\mathbf{U}^H \mathbf{R} \mathbf{U}\} + \text{Trace}\{\mathbf{H}(\mathbf{I} - \mathbf{U}^H \mathbf{U})\},$$

where $\mathbf{U}$ is a $d \times (d - p)$ matrix whose columns are given by $\mathbf{e}_i$. Now by minimizing $\tilde{J}$ with respect to $\mathbf{U}$ show that the solution satisfies $\mathbf{R} \mathbf{U} = \mathbf{U} \mathbf{H}$. Clearly, one possible solution is that the columns of $\mathbf{U}$ are eigenvectors of $\mathbf{R}$, in which case $\mathbf{H}$ is a diagonal matrix containing the corresponding eigenvalues. To obtain the general solution, show that $\mathbf{H}$ can be assumed to be a symmetric matrix, and by using its eigenvector expansion show that the general solution to $\mathbf{R} \mathbf{U} = \mathbf{U} \mathbf{H}$ gives the same value for $\tilde{J}$ as the specific solution in which the columns of $\mathbf{U}$ are the eigenvectors of $\mathbf{R}$. Because these solutions are all equivalent, it is convenient to choose the eigenvector solution.

ΒΙΒΛΙΟΓΡΑΦΙΑ:

- [1] Γ. Καραγιάννης και Γ. Σταϊνχάουερ, *Αναγνώριση Προτύπων και Μάθηση Μηχανών*, EMPI, 2001.
- [2] R. O. Duda, P.E. Hart and D.G. Stork, *Pattern Classification*, Wiley, 2001.
- [3] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [4] S. Theodoridis and K. Koutroumbas, *Pattern Recognition*, 4th Edition Academic Press, Elsevier, 2009. *Ελληνική μετάφραση: απόδοση-επιμέλεια-πρόλογος ελληνικής έκδοσης Α. Πικράκης, Κ. Κουτρομπάς, Θ. Γιαννακόπουλος, Επιστημονικές Εκδόσεις Π.Χ. Πασχαλίδης-Broken Hill Publishers LTD, 2012.*
- [5] S. Theodoridis, *Machine Learning: a Bayesian and Optimization Perspective*. Academic Press, 2015.